



INSTITUT DE STATISTIQUE DE SORBONNE UNIVERSITÉ

RAPPORT DE MACHINE LEARNING

Prédiction de la gravité des accidents corporels routiers via Machine Learning

Nicolas COBAN, Mouhamadou SECK, Hugo SEUMEN, Ilies ZOUATNIA



Encadré par
Kezhan SHI, Arnaud Cohen

Janvier 2025

Table des matières

1	Présentation des données et du projet	2
1.1	Problématique	2
1.2	Présentation de la base de données	2
1.3	Nettoyage des données	3
1.4	Analyse exploratoire	4
2	Machine Learning	6
2.1	Préparation des données	6
2.2	Modélisation	7
2.3	Résultats préliminaires	8
2.4	Optimisation XGBoost	9

Introduction

Dans un contexte où la gestion des risques et l’optimisation des coûts sont des priorités stratégiques pour les compagnies d’assurance, ce projet explore l’utilisation du Machine Learning pour mieux prédire les événements liés à l’assurance automobile. Les accidents de la route représentent un enjeu critique, nécessitant de couvrir les sinistres tout en préservant l’équilibre financier des compagnies. Les primes d’assurance doivent refléter avec précision le risque réel associé aux conducteurs et aux circonstances des accidents, tout en restant attractives pour fidéliser les clients. Cette équation complexe demande une analyse fine des multiples facteurs influençant la probabilité et la gravité des accidents.

1 Présentation des données et du projet

1.1 Problématique

Ce projet a pour ambition de concevoir un modèle prédictif capable d’estimer la gravité d’un accident de la route. Pour cela, il s’appuie sur une analyse approfondie des données incluant les conditions environnementales (comme la météo, l’état des routes, ou la visibilité), les profils des usagers (âge, sexe, ...) ainsi que les caractéristiques des véhicules impliqués (type, point de choc).

L’objectif est d’aller au-delà de la simple prédiction en identifiant avec précision les facteurs de risque spécifiques qui influencent les accidents. Cette compréhension approfondie permettra de proposer des solutions adaptées, telles qu’une tarification plus juste et personnalisée, des politiques de prévention ciblées ou encore une segmentation fine des assurés en fonction de leurs niveaux de risque.

1.2 Présentation de la base de données

Pour réaliser notre étude, nous nous sommes appuyés sur une base de données de 4 rubriques, extraites du fichier BAAC administré par l’Observatoire National Interministériel de la Sécurité Routière (ONISR), qui répertorient l’intégralité des accidents corporels de la circulation, intervenus durant une année précise en France métropolitaine, dans les départements d’Outre-mer (Guadeloupe, Guyane, Martinique, La Réunion et Mayotte depuis 2012) et dans les autres territoires d’outre-mer (Saint-Pierre-et-Miquelon, Saint-Barthélemy, Saint-Martin, Wallis-et-Futuna, Polynésie française et Nouvelle-Calédonie ; disponible qu’à partir de 2019 dans l’open data) avec une description simplifiée. Cela comprend des informations de localisation de l’accident, telles que renseignées ainsi que des informations concernant les caractéristiques de l’accident et son lieu, les véhicules impliqués et leurs victimes.

Comme mentionné précédemment, la base de données des accidents corporels de la circulation d’une année donnée, est répartie en 4 rubriques sous la forme pour chacune d’elles d’un fichier au format csv.

- La rubrique **CARACTÉRISTIQUES** qui décrit les circonstances générales de l’accident.
- La rubrique **LIEUX** qui décrit le lieu principal de l’accident même si celui-ci s’est déroulé à une intersection.
- La rubrique **VÉHICULES** qui décrit les véhicules impliqués.
- La rubrique **USAGERS** qui décrit les usagers impliqués.

Ces bases occultent néanmoins certaines données spécifiques relatives aux usagers et aux véhicules et à leur comportement dans la mesure où la divulgation de ces données porterait atteinte à la protection de la vie privée des personnes physiques aisément identifiables ou ferait apparaître le comportement de telles personnes alors que la divulgation de ce comportement pourrait leur porter préjudice.

Ces données, issues du fichier national des accidents corporels (BAAC), offrent un cadre riche et pertinent pour explorer ces enjeux en utilisant des modèles de machine learning adaptés.

1.3 Nettoyage des données




FIGURE 1 – Schéma du nettoyage des données

Notre base de données initiale comporte un total de 126 662 observations pour 57 variables. L'objectif principal de ce projet étant de prédire les accidents graves, une transformation spécifique a été appliquée à la variable cible, la gravité des accidents (**grav**). Cette variable, initialement multi-classes (Indemne, Blessé léger, Blessé hospitalisé, Tué), a été simplifiée en une colonne binaire nommée "**sinistre**". Cette nouvelle colonne indique si une personne impliquée dans un accident est blessée ou indemne, en regroupant les niveaux de gravité Blessé léger et Blessé hospitalisé dans une même catégorie. En RC Automobile, les garanties liées aux dommages corporels étant en illimité, c'est donc ce facteur que les compagnies d'assurance essaient de maîtriser. De plus, cette simplification permet de transformer le problème en une tâche de classification binaire, facilitant ainsi la modélisation et l'interprétation des résultats.


Ensuite, une consolidation des données temporelles a été réalisée. Les informations provenant des colonnes relatives à l'année, au mois, au jour et à l'heure ont été combinées en une seule variable **date_heure**, formatée en **datetime**. Cette étape simplifie l'analyse des tendances temporelles, telles que les variations horaires ou saisonnières. À partir de cette colonne, de nouvelles variables ont été créées, comme le jour de la semaine (**jour_semaine**), l'heure, ou encore des représentations circulaires de l'heure (**heure_sin** et **heure_cos**). Ces représentations trigonométriques permettent de mieux capturer les variations cycliques des accidents au cours de la journée, tout en évitant les discontinuités entre les valeurs extrêmes (par exemple, entre 23h et minuit).

Un enrichissement des données a également été réalisé avec la création de la variable **age_victime**, calculée en soustrayant l'année de naissance des victimes de l'année de l'accident. Cette variable est essentielle pour identifier des groupes spécifiques à risque, comme les jeunes conducteurs ou les personnes âgées. Les observations où l'âge des victimes était manquant ont été supprimées pour garantir la cohérence et la qualité des données.

Les colonnes jugées redondantes ou peu pertinentes, comme certains identifiants ou variables fortement corrélées, ont été supprimées pour alléger le jeu de données et réduire le bruit. De plus, les colonnes contenant plus de 98% de valeurs manquantes ont été éliminées, et un filtrage des lignes avec des valeurs incohérentes a été appliqué, notamment sur des variables comme le nombre de voies (**nbv**) et la largeur de la route (**larout**). Pour cette dernière, majoritairement remplie de valeurs par défaut

(-1), une suppression totale a été décidée après avoir constaté sa faible utilité et sa redondance avec la variable `nbv` (la largeur des voies étant réglementé, on peut supposer que la variable `larout` est un multiple de `nbv`).


1.4 Analyse exploratoire



(a) Cartes des accidents dans le 93



(b) Cartes des accidents dans le 95



(c) Cartes des accidents à Paris

FIGURE 2 – Cartes des accidents en Île-de-France

Ces cartes illustrent la répartition des accidents de la route dans trois départements : le Val-d'Oise (95), la Seine-Saint-Denis (93) et Paris (75). Chaque point représente un accident, et sa couleur indique les conditions atmosphériques au moment de l'incident.

Dans le Val-d'Oise, les accidents sont principalement localisés autour des grandes agglomérations comme Argenteuil, ainsi que sur les principaux axes routiers. En Seine-Saint-Denis, les accidents couvrent l'ensemble du territoire, avec une concentration plus marquée autour de villes comme Saint-Denis et Montreuil. À Paris, les accidents sont répartis sur tout le périmètre de la ville, ce qui reflète l'intensité des interactions entre les véhicules et les usagers vulnérables, notamment les piétons et les cyclistes.

Les conditions atmosphériques les plus fréquentes lors des accidents sont normales (temps clair ou légèrement couvert). Les accidents sous pluie légère arrivent en seconde position, suivis par ceux survenant lors de fortes pluies. Cette répartition suggère que, bien que la météo puisse influencer les risques, d'autres facteurs, comme la circulation dense et les infrastructures routières, jouent un rôle plus déterminant.

Ces observations mettent en évidence la nécessité d'adapter les politiques de sécurité routière aux spécificités locales. Par exemple, à Paris, il est essentiel de gérer les interactions entre les différents usagers de la route tels que les automobilistes, les motos et les cyclistes.




FIGURE 3 – Répartition des accidents par type de route et gravité

Ce graphique montre la répartition des accidents par région en fonction de leur gravité. L'Île-de-France, avec son trafic dense et une forte concentration de population, enregistre un volume élevé d'accidents, mais la répartition entre indemnes et blessés hospitalisés reste comparable à celle observée dans des régions comme l'Auvergne-Rhône-Alpes ou l'Occitanie. Ces régions, marquées par des flux interurbains et touristiques, présentent des volumes d'accidents importants, mais des proportions similaires de gravité. Même dans les régions d'outre-mer, où le nombre total d'accidents est plus faible, la répartition entre ces deux catégories demeure cohérente avec le reste du territoire.

Pour les assureurs, ces données soulignent l'importance d'une tarification équilibrée, prenant en compte les fréquences plus élevées dans les zones urbaines comme l'Île-de-France, tout en gardant à l'esprit que gravité reste inchangé en proportion entre les régions.




FIGURE 4 – Distribution des accidents selon l'âge et la gravité

Les histogrammes révèlent que les jeunes adultes sont majoritaires dans toutes les catégories d'accidents, mais les décès présentent une répartition plus équilibrée. Les jeunes adultes, souvent impliqués dans des comportements à risque (vitesse, imprudence), sont sur-représentés dans les accidents mortels. Cependant, les personnes plus âgées occupent également une place significative dans cette catégorie, en raison de leur vulnérabilité accrue, même lors de collisions moins violentes.

2 Machine Learning

2.1 Préparation des données

Le Machine Learning repose sur des modèles statistiques et mathématiques qui permettent d'établir des liens entre des variables explicatives, que l'on connaît, et une variable cible, que l'on cherche à prédire. Dans notre cas, les variables explicatives représentent les caractéristiques des accidents (par exemple, les conditions environnementales ou les types de véhicules impliqués), tandis que la variable cible indique si une victime d'accident finit blessé ou indemne.

Le processus de modélisation s'articule autour de deux phases principales. La première est la phase d'apprentissage, où l'on entraîne un modèle en utilisant un ensemble de données comprenant à la fois les variables explicatives et la variable cible. Ce type d'approche, appelé **apprentissage supervisé**, per-

met au modèle d'apprendre les relations entre les variables pour effectuer des prédictions. La deuxième phase est la phase de prédiction, durant laquelle le modèle, une fois entraîné, est utilisé pour prédire la variable cible sur de nouvelles données.

Pour le prétraitement des données, un **ColumnTransformer** a été employé pour gérer différemment les variables numériques et catégoriques. Les variables numériques ont été conservées telles quelles, tandis que les variables catégoriques ont été transformées avec un encodage **One-Hot Encoding**, qui permet de représenter chaque catégorie comme un vecteur binaire. Cette étape est cruciale pour rendre les données catégoriques compréhensibles par les modèles de machine learning et éviter les relation d'ordre.




FIGURE 5 – Schéma du One-Hot Encoding

Pour garantir une évaluation fiable de la performance du modèle, les données ne sont pas utilisées en totalité pour l'entraînement. Elles sont divisées en deux ensembles : un **train set**, utilisé pour construire le modèle, et un **test set**, servant à évaluer sa capacité à généraliser sur des données inconnues. Ici, 80% de nos données ont été réservées à l'apprentissage et les 20% restantes au test. Cette séparation est essentielle pour éviter l'**overfitting** et pour obtenir une mesure précise des performances du modèle sur nos données.

2.2 Modélisation

Nous avons commencé par entraîner 4 modèles simple avec leurs hyperparamètres de base :

- **XGBoost**
- **Random Forest**
- **Réseau de neurones à 3 couches**
- **Support Vector Machine (SVM)**

Pour évaluer les performances des modèles de machine learning, nous avons défini une fonction d'évaluation qui inclut plusieurs étapes. Tout d'abord, le modèle est entraîné sur les données d'entraînement, puis testé sur les données de validation. Les performances sont mesurées à l'aide de la matrice de confusion et d'un rapport de classification. La métrique d'évaluation que nous avons choisi est le **recall**. Ce choix repose sur la priorité donnée à la détection des sinistres engendrant des blessées, où il est crucial de minimiser les faux négatifs. En effet, ne pas identifier une victime blessée pourrait avoir des conséquences importantes en termes de gestion des risques et des coûts d'indemnisations.

$$\text{Recall} = \frac{\text{Vrais Positifs (TP)}}{\text{Vrais Positifs (TP)} + \text{Faux Négatifs (FN)}}$$

Nous avons également calculé les **learning curves**, qui permettent de visualiser l'évolution des performances d'entraînement et de validation en fonction de la taille des données d'entraînement. Ces

courbes sont particulièrement utiles pour détecter des problèmes d'**overfitting** ou d'**underfitting** et pour évaluer l'efficacité de l'entraînement du modèle.

2.3 Résultats préliminaires



FIGURE 6 – Learning curves des différents modèles

Les courbes d'apprentissage pour le **Réseau de neurones** révèlent un comportement classique d'apprentissage progressif. À mesure que la taille des données augmente, le score d'entraînement diminue légèrement, reflétant la généralisation du modèle. Parallèlement, le score de validation suit une tendance ascendante, montrant que l'ajout de données améliore la capacité du modèle à prédire correctement sur des données nouvelles. Toutefois, l'écart persistant entre les deux courbes suggère que le modèle pourrait encore bénéficier d'un ajustement des **hyperparamètres** pour mieux équilibrer la performance.

Pour le **SVM**, les courbes montrent une convergence presque parfaite entre le score d'entraînement et celui de validation. Cela indique une bonne généralisation sans **overfitting** ni sous-apprentissage. Cependant, un comportement atypique est observé avec une chute notable du score après un pic initial, ce qui pourrait être dû à une sensibilité du modèle à certaines données ou à un besoin d'ajuster davantage ses paramètres pour stabiliser les performances.

En ce qui concerne la **Random Forest** montre un exemple typique d'**overfitting**. La courbe d'entraînement reste constamment élevée, indiquant une mémorisation parfaite des données d'entraînement, tandis que le score de validation reste nettement plus bas et presque plat. Cette incapacité à généraliser reflète une complexité excessive du modèle, nécessitant une réduction de la profondeur des arbres ou du nombre d'estimateurs pour améliorer sa performance sur des données nouvelles.

Enfin, pour **XGBoost**, les courbes affichent une performance stable et équilibrée. Les scores d'entraînement et de validation convergent progressivement à mesure que la taille des données augmente, suggérant que le modèle utilise efficacement les données disponibles. Ce comportement indique une bonne adaptation du modèle au problème. Parmi les modèles analysés, **XGBoost** se distingue comme étant le plus robuste.

2.4 Optimisation XGBoost

Pour améliorer les performances du modèle **XGBoost**, une optimisation des **hyperparamètres** a été réalisée à l'aide de **RandomizedSearchCV**. Cette méthode permet d'explorer un sous-ensemble aléatoire de l'espace des **hyperparamètres**, constituant un bon compromis entre qualité des résultats et temps de calcul.

Hyperparamètres optimisés :

- **n_estimators** : Nombre d'arbres, testé entre 50 et 300 par pas de 50.
- **max_depth** : Profondeur maximale des arbres, testée entre 3 et 9.
- **learning_rate** : Taux d'apprentissage, exploré entre 0.01 et 0.3.

Configuration de RandomizedSearchCV :

- **n_iter** = 10 : Limitation à 10 itérations pour réduire le temps de calcul.
- **scoring** = **recall** : Utilisation du **recall** comme métrique pour minimiser les faux négatifs.
- **cv** = 2 : Validation croisée à 2 plis pour évaluer les performances.
- **n_jobs** = -1 : Parallélisation sur tous les cœurs disponibles.

Résultats

Les meilleurs hyperparamètres trouvés sont :

- **n_estimators** : 250
- **max_depth** : 5
- **learning_rate** : 0.171

	Precision	Recall	F1-Score
False	0.74	0.76	0.75
True	0.82	0.80	0.81
Accuracy		0.79	
Macro Avg	0.78	0.78	0.78
Weighted Avg	0.79	0.79	0.79

TABLE 1 – XGBoost

	Precision	Recall	F1-Score
False	0.77	0.77	0.77
True	0.83	0.83	0.83
Accuracy		0.81	
Macro Avg	0.80	0.80	0.80
Weighted Avg	0.81	0.81	0.81

TABLE 2 – XGBoost optimisé

Avant optimisation, le modèle XGBoost affichait un **recall** de 0.76 pour la classe "False" et de 0.80 pour la classe "True", reflétant une capacité correcte mais perfectible à identifier les cas positifs et négatifs. L'**accuracy** globale était de 0.79, avec des **moyennes pondérées** et **macro** de 0.79 et 0.78. Après optimisation, le **recall** pour la classe "True" a progressé à 0.83, tandis que celui pour "False" s'est stabilisé à 0.77. Cette amélioration du **recall**, particulièrement pour la classe "True", est essentielle dans le contexte de notre projet, où la détection des victimes blessées (classe positive) est prioritaire. Une augmentation du **recall** signifie que le modèle détecte davantage de cas positifs, réduisant ainsi les faux négatifs, un objectif clé pour l'analyse des risques.

En résumé, l'optimisation des **hyperparamètres** a renforcé les performances globales.

Importance des variables




FIGURE 7 – Importance des variables XGBoost

Les résultats de l'analyse des importances mettent en évidence des groupes de variables clés qui influencent les prédictions du modèle. Plutôt que de se concentrer uniquement sur les coefficients individuels, il est intéressant de regrouper les variables par thématiques pour mieux comprendre leur contribution.

Le groupe dominant est constitué des **facteurs routiers et comportementaux**, comprenant des variables telles que **vma** (vitesse maximale autorisée), **manv** (manœuvre), et **obsm** (obstacle mobile). Ces variables soulignent l'impact crucial de la configuration des routes et des comportements des conducteurs sur la survenue et la gravité des accidents. Cela met en évidence l'importance des infrastructures routières et du respect des règles de conduite.

Les **caractéristiques des véhicules et des chocs**, représentées par des variables comme **motor** (type de motorisation) et **choc** (type de choc), jouent également un rôle significatif. Ces éléments révèlent l'influence des spécificités des véhicules et des types de collisions, fournissant des pistes pour développer des politiques d'assurance adaptées.

Le groupe des **profils des victimes**, avec la variable **age_victim**, montre que l'âge des victimes est un facteur clé. Certaines tranches d'âge, comme les jeunes conducteurs et les seniors, présentent une vulnérabilité accrue, justifiant des stratégies ciblées pour ces segments d'assurés.

Les **facteurs géographiques et temporels**, tels que **long**, **lat**, **heure_sin**, et **heure_cos**, contribuent de manière modérée. Ces variables permettent d'identifier des zones et des périodes à risque, bien que leur influence soit secondaire par rapport aux comportements routiers.

Enfin, les **conditions environnementales**, représentées par des variables comme **atm** (conditions atmosphériques) et **lum** (luminosité), ont un rôle limité mais restent pertinentes.

En résumé, les comportements routiers et les caractéristiques des véhicules dominent l'analyse des importances, suivis des profils des victimes, tandis que les facteurs géographiques et environnementaux

ont une influence plus marginale. Cette segmentation des groupes de variables pourrait offrir des axes clairs pour ajuster les politiques de prévention et de tarification dans une optique assurantielle.

Conclusion

Ce projet a permis de concevoir un modèle performant pour prédire la gravité des accidents de la route, en s'appuyant sur des techniques de Machine Learning et une préparation rigoureuse des données. Parmi les modèles testés, XGBoost s'est démarqué par sa robustesse et sa capacité à détecter les sinistres graves en minimisant les faux négatifs.

Cependant, plusieurs pistes d'amélioration peuvent être envisagées. L'utilisation des réseaux de neurones, plus adaptés pour capturer des relations complexes, est restée limitée en raison des contraintes de temps et de calcul. Enfin, une analyse approfondie des interactions entre variables offrirait des insights supplémentaires pour affiner le modèle.